

Análise Comparativa de Agrupamentos Não Supervisionados: K-Means e Single Linkage

A aplicação dos algoritmos K-Means e Single Linkage mostra que o sucesso deles depende muito da geometria dos dados. O K-Means trabalha tentando agrupar os dados ao redor de um ponto central. Por causa dessa lógica, ele sempre espera encontrar grupos redondos e bem concentrados. Quando ele se depara com dados que formam desenhos alongados, em anel ou irregulares, ele acaba falhando e fazendo cortes retos e artificiais na figura.

Já o Single Linkage funciona de um jeito diferente. Ele vai ligando os pontos que estão mais próximos uns dos outros. Isso, em teoria, ajuda a capturar formatos irregulares que o K-Means não consegue. Porém, o Single Linkage sofre de um grande defeito, pois se houver alguns pontos soltos formando uma "ponte" muito fina entre dois grupos que deveriam estar separados, o algoritmo se confunde e acaba juntando tudo em um único grupo gigante.

Para garantir uma avaliação justa do comportamento dos algoritmos, a execução dos códigos foi dividida em duas abordagens distintas para cada base de dados. Na primeira etapa, os algoritmos foram testados com o parâmetro K (número de clusters) variável dentro de um intervalo lógico, permitindo observar as tendências matemáticas de divisão e como o Índice Rand reagia a essas escolhas livres. Na segunda etapa, sabendo previamente a quantidade real de classes de cada dataset, realizou-se uma nova iteração com o valor de K fixado no número ideal. O objetivo dessa segunda abordagem foi comprovar se forçar a quantidade correta de grupos ajudaria os algoritmos a encontrar o agrupamento real ou se, como comprovado nas análises a seguir, as limitações geométricas do K-Means e do Single Linkage continuariam sobrepondo o acerto da quantidade de classes.

Neste exercício, decidi usar o índice Rand presente nos slides de aula.

Figura 1: fórmulas de Índices Externos de Validação (Índice Rand)

Índices externos

- **Rand:** $\frac{(A + D)}{(A + B + C + D)}$
- **Jaccard:** $\frac{A}{A + B + C}$
- **Folkes e Mallows:** $\sqrt{\frac{A}{A + B} * \frac{A}{A + C}}$

Esses índices variam entre $[0,1]$, valores altos indicam alta similaridade entre os grupos e as partições


Fonte: Material de aula, Prof. Dra. Lilian Berton.

Ele provou não ser uma métrica confiável para avaliar os gráficos, dando notas muito altas para agrupamentos que visivelmente deram errado. Isso acontece porque a fórmula dele valoriza muito os Verdadeiros Negativos (pontos de grupos diferentes que o algoritmo conseguiu colocar em grupos diferentes). Como essas bases de dados têm muitos pontos e várias classes, qualquer algoritmo que divida os dados vai acertar a maioria desses casos por pura estatística. Esse volume de acertos aumenta a nota final e mascara os erros que vemos nas imagens.

Dataset Agregation:

Apesar da nota alta do Índice Rand (acima de 0.93), as imagens provam que os algoritmos erraram. O K-Means fatiou o grupo que fica na região inferior porque o formato dele era muito largo, o que vai contra a lógica de formar círculos fechados do algoritmo. O Single Linkage fundiu as duas grandes estruturas do lado direito porque havia uma pequena trilha de pontos soltos entre elas. A nota do Rand só ficou alta nos dois algoritmos porque eles acertaram os agrupamentos menores e isolados da esquerda, e porque havia uma grande quantidade de Verdadeiros Negativos.


Figura 2: Resultado do dataset agregation para k variável.



Fonte: Autora.

Figura 3: Resultado do dataset aggregation para k fixo igual a 7.

Melhor resultado:
K-Means (Melhor K = 7): 0.9192
Single Linkage (Melhor K = 7): 0.9257




Fonte: Autora.

Dataset D31:

O dataset D31 é o cenário perfeito para o K-Means. Como ele possui 31 grupos que já são naturalmente circulares e bem espaçados, o algoritmo consegue delimitar os grupos com facilidade (chegando a um Índice Rand muito próximo de 1.00). Em contrapartida, o Single Linkage não foi muito eficiente. Pelo excesso de pontos e a proximidade entre os grupos, ele mesclou os limites de clusters que eram vizinhos.

Figura 4: Resultado do dataset D31 para k variável.


Melhor resultado:
K-Means (Melhor K = 34): 0.9955
Single Linkage (Melhor K = 33): 0.7794



Fonte: Autora.

Figura 5: Resultado do dataset D31 para k fixo igual a 31.

Melhor resultado:
K-Means (Melhor K = 31): 0.9916
Single Linkage (Melhor K = 31): 0.7789




Fonte: Autora.

Dataset Path-Based1:

Visualmente, a expectativa era separar os dois aglomerados centrais do arco que está ao redor. O K-Means fez cortes retos que ignoram o formato do arco, quebrando-o e misturando-o com os dados do centro. O Single Linkage também falhou na separação, pois como a distância entre as pontas do arco e os grupos centrais é muito pequena, ele acabou unindo essas duas estruturas diferentes através de uma ponte de pontos, isolando apenas alguns grupos na parte de baixo.

Figura 6: Resultado do dataset Path-Based1 para k variável.


Melhor resultado:
K-Means (Melhor K = 3): 0.7478
Single Linkage (Melhor K = 6): 0.5129



Fonte: Autora.

Figura 7: Resultado do dataset Path-Based1 para k fixo igual a 3.

Melhor resultado:
K-Means (Melhor K = 3): 0.7478
Single Linkage (Melhor K = 3): 0.3377




Fonte: Autora.

Dataset Flame:

O K-Means não conseguiu "dobrar" para entender a forma em "U" da base de dados e acabou fatiando a figura em pedaços na tentativa de criar grupos circulares. O Single Linkage, por outro lado, por causa da proximidade contínua dos pontos, uniu quase todos os dados em um único grupo, isolando apenas alguns pontos distantes no topo como se fossem grupos separados.

Figura 8: Resultado do dataset Flame para k variável.



Melhor resultado:
K-Means (Melhor K = 3): 0.7579
Single Linkage (Melhor K = 4): 0.5430



Fonte: Autora.

Figura 9: Resultado do dataset Flame para k fixo igual a 2.

Melhor resultado:
K-Means (Melhor $K = 2$): 0.7324
Single Linkage (Melhor $K = 2$): 0.5406



Fonte: Autora.